설비 고장을 예측하는 AI 데이터 분석

Pandas 집계·기초 통계

빈도와 그룹 집계

CONTENTS

목차

01 빈도 집계 — 값별 개수와 비율, 구간으로 묶어 세기

02 그룹 집계 — 분할·적용·결합, 여러 기준으로 나눠 보기

03 종합 실습 — 빈도와 그룹을 이어 보기

posco

이 단원의 데이터 — 유압 시스템 상태 감시

원본 수업 자료는 60초 사이클 단위로 설명 · 이번 분석은 제공된 CSV 범위에 한정

01

사이클 표 · 120행 × 8열

냉각기상태 · 운전부하 · 밸브상태
온도 · 진동 · 압력 · 냉각효율
result: 제공 파일의 정상/고장 라벨

02

품질검사 표 · 200행 × 11열

검사결과: 합격 188건 / 불합격 12건
수치형 지표 10개
이번 단원에서는 건수와 비율을 확인

03

해석 범위부터 확인

원본 추출·가공 절차와 result 생성 기준은 미제공
냉각기상태와 result를 같은 판정으로 가정하지 않음
실제 고장 확률·현장 기준으로 일반화하지 않음

파일의 값은 유지합니다. 정의가 없는 라벨을 임의의 규칙으로 다시 만들지 않습니다.

posco

01

빈도 집계

값별 개수와 비율 · 수치형을 구간으로 묶어 세기

행 하나하나 보기의 한계

120행도 한 줄씩 읽기는 어렵다 — 요약해 전체를 한눈에

행을 하나씩 읽는 대신 요약해 전체 파악

사이클 120개 × 열 8개 = 값 960개 — 눈으로 읽어 구성을 파악하기는 어려움

집계란 여러 값을 한 숫자로 압축

집계로 답할 수 있는 질문

빈도 → 그룹 비교 → 관계의 세 질문

01

01 · 빈도

어떤 값이 가장 많은가?
밸브 상태별 건수와 비율로
데이터의 구성을 파악한다.

02

02 · 그룹 비교

그룹마다 수준이 다른가?
냉각기 상태별 온도 평균으로
전체 평균에 가려진 차이를 본다.

03

03 · 관계

두 수치는 어떤 관계를 보이는가?
다음 14_02에서 온도와 냉각효율의
선형 상관을 확인한다.

이번 단원은 빈도와 그룹 집계까지 · 다음 단원에서 그룹 통계와 상관관계로 확장

범주형과 수치형 데이터

셀 수 있는 데이터 구분이 먼저 — 설비 데이터는 두 종류가 섞여 있음

01 · 수치형

숫자로 측정, 평균·합계 가능

온도 45.3도 — 더하거나 평균 낼 수 있는 측정값

02 · 범주형

종류로 구분, 빈도 집계 대상

정상 · 저하 · 고장 — 종류를 나타내는 값

03 · 빈도란

각 종류가 몇 번 나오는지

범주형에서 빛을 발하는 첫 번째 집계

숫자가 들어 있어도 이름 대신 쓰는 값이면 범주형 — 쓰임이 구분 기준

value_counts로 개수 세기

한 열에 어떤 값이 몇 번씩 나오는지 자동으로 세는 도구

01 · 이름의 뜻

value(값)를 counts(센다) — 이름 그대로의 동작

02 · 사용법

세고 싶은 열을 고른 뒤 점을 찍고 붙이기

03 · 출력 정렬

가장 많은 종류부터 자동 정렬되어 출력

이번에는 한 열의 빈도 · df.value_counts()는 행의 값 조합별 빈도를 계산

value_counts 기본 코드

열을 고른 뒤 값별 건수 세기

CODE

```
print(df["냉각기상태"].value_counts())
# 고장 40 · 저하 40 · 정상 40 (동률의 표시 순서는 다를 수 있음)

print(df["밸브상태"].value_counts())
# 정상 61 · 지연 20 · 경미 20 · 심각 19

print(df["result"].value_counts())
# 정상 67 · 고장 53
```

값과 건수를 확인합니다. 동률 항목의 출력 순서 자체는 정답 기준이 아닙니다.

개수를 비율로 바꾸기

개수 + 비율 — 둘을 함께 봐야 진짜 감이 잡힘

01 · 개수만의 한계

개수만으로는 많고 적음 판단 어려움

02 · 비율의 역할

전체에서 차지하는 비율로 봐야 비중이 보임

03 · 공정한 비교

규모가 다른 대상을 비교할 때 필수

1공장 불량 50건 vs 2공장 30건 — 생산량을 고려한 비율(1% vs 6%)이 실체를 보여줌

normalize로 비율 구하기

기본은 결측이 아닌 값의 개수를 분모로 사용

CODE

```
counts = df["result"].value_counts()
ratios = df["result"].value_counts(normalize=True)
print(counts)           # 정상 67 · 고장 53
print(ratios.round(3))    # 정상 0.558 · 고장 0.442
print((ratios * 100).round(1))  # 정상 55.8 · 고장 44.2 (%)

# 결측까지 하나의 종류로 포함하려면 두 옵션을 함께 지정합니다.
print(df["result"].value_counts(
    normalize=True, dropna=False).round(3))
```

현재 CSV에는 결측이 없습니다. 반올림된 비율의 합은 정확히 1이 아닐 수 있습니다.

정렬과 결측값 옵션

빈도순 정렬을 끄는 것과 원하는 순서를 지정하는 것은 다르다

01

sort=False

빈도순으로 정렬하지 않음
이 파일의 문자열 열에서는 등장 순서로 표시
정상 → 경미 → 지연 → 심각 순서를 보장하지 않음

02

reindex(원하는 순서)

counts.reindex(order, fill_value=0)
order에 상태 이름 순서를 직접 지정
없는 상태는 0건으로 표시할 수 있음

03

dropna=False

결측도 한 종류로 포함해 셈
normalize=True와 함께 쓰면
결측을 포함한 전체 행 수가 분모

숫자가 같은 항목의 표시 순서보다, 상태 이름과 그 건수가 맞는지 확인합니다.

실습 1. 값별 개수 세어 보기

범주 열의 값이 몇 번씩 나오는지 세어 데이터 구성 파악

목표

밸브 상태와 운전 부하의 값별 건수를 세어 표의 구성을 확인

단계

① 유압 사이클 파일을 읽어 전체 크기를 확인

② 밸브 상태 열의 값별 건수와 비율을 출력

③ 운전 부하 열의 건수와 비율도 같은 방법으로 출력

④ 최대·최소 건수에 해당하는 값을 찾기 (동률은 모두 확인)

예상 결과

밸브는 정상 61 · 지연 20 · 경미 20 · 심각 19 · 운전 부하는 60 대 60

불균형 데이터의 의미

실제 고장·불량 데이터에서 확인해야 할 분포 특성 — 빈도 확인이 함정 회피의 첫 단추

고장·불량 데이터는 정상 쪽으로 쏠릴 수 있으므로 실제 분포 확인

쏠린 데이터에서는 「무조건 다수 쪽」이라 찍어도 정확도가 높게 나옴

빈도를 미리 확인하면 이 함정을 피할 수 있음

고장 예측 모델의 정확도에 속지 않으려면 — 빈도 확인이 첫 안전장치

실습 2. 비율로 치우침 확인하기

건수와 비율을 함께 구해 한쪽으로 심하게 치우친 데이터를 확인

목표

품질검사 표의 합격·불합격 건수와 비율을 구해 치우침의 정도를 확인

단계

① 품질검사 파일을 읽어 전체 크기를 확인

② 검사 결과 열의 값별 건수를 세어 출력

③ 같은 열의 비율을 구해 소수점 셋째 자리까지 정리해 출력

④ 불합격 비율을 백분율로 바꿔 말로 표현

예상 결과

합격 188 · 불합격 12 · 비율 0.94 대 0.06 — 불합격이 전체의 약 6%

수치형을 구간으로 묶어 세기

먼저 묶고, 그 다음에 셈 — 순서가 핵심

STEP 1

pd.cut으로 구간 묶기

숫자를 정해진 경계에서 잘라 구간으로 묶음

예: (0, 40] 낮음 · (40, 50] 보통 · (50, 200] 높음

STEP 2

value_counts 붙이기

만든 구간 데이터에 붙여 구간별 빈도 세기

구간 → 개수의 두 단계 흐름

이번 경계는 수업용 예시입니다. 실제 정상·위험 기준은 설비 사양과 운전 조건으로 검증합니다.

숫자를 묶으면 분포가 보인다

온도 값을 구간으로 바꾸고, 구간별 건수를 센다

01

낮음 · 41건

0 < 온도 ≤ 40
35.3 · 35.6 · 36.4 등이 포함
낮음은 실습용 구간 이름

02

보통 · 40건

40 < 온도 ≤ 50
44.0 · 47.2 등이 포함
40은 앞 구간, 50은 이 구간

03

높음 · 39건

50 < 온도 ≤ 200
51.2 · 54.9 · 57.8 등이 포함
높음이 곧 실제 고장이라는 뜻은 아님

수치형도 빈도를 셀 수 있습니다. 고유값이 많을 때 구간 집계가 분포를 읽기 쉽게 만듭니다.

posco

pd.cut 구간 빈도 코드

경계 4개 → 구간 3개 · right=True는 오른쪽 경계 포함

CODE

```
band = pd.cut(
    df["온도"], bins=[0, 40, 50, 200],
    labels=["낮음", "보통", "높음"], right=True
)
print(band.value_counts(sort=False))
# 낮음 41 · 보통 40 · 높음 39
print("구간 미지정:", band.isna().sum())  # 0
print("검산:", band.value_counts().sum())  # 120
```

범위 밖 값과 원래 결측값은 NaN이 됩니다. 0은 기본 설정에서 첫 구간에 포함되지 않습니다.

경계값은 어느 구간에 들어갈까?

pd.cut(..., bins=[0, 40, 50, 200], right=True) 기준

값	들어가는 구간	확인할 점
0	NaN	왼쪽 첫 경계는 기본적으로 제외
40	낮음: (0, 40]	오른쪽 경계 40은 포함
50	보통: (40, 50]	50은 높음이 아니라 보통
200	높음: (50, 200]	마지막 오른쪽 경계도 포함
201 또는 결측	NaN	범위 밖 값 또는 원래 결측

include_lowest=True면 첫 경계 0도 포함 · right=False면 왼쪽 포함·오른쪽 제외로 바뀜

실습 3. 구간으로 묶어 세어 보기

수치형 열을 구간으로 나눈 뒤 구간별 건수를 세어 분포 확인

목표

진동 값의 범위를 확인하고 세 구간으로 묶어 어디에 몰려 있는지 파악

단계

① 유압 사이클 파일에서 진동 열의 최솟값과 최댓값을 확인

② 경계 [0, 0.6, 0.7, 10], 이름표 [약함, 보통, 강함]으로 묶기

③ 구간별 건수와 구간 미지정(NaN) 개수를 출력

④ 최대·최소 구간을 확인 (응용: 경계 0.6을 0.62로 변경)

예상 결과

진동 범위는 0.53 ~ 0.779 · 보통 55 · 약함 48 · 강함 17

02

그룹 집계

분할 · 적용 · 결합 — 기준을 정해 나눠 보기

그룹으로 나눠 보는 이유

전체 평균 하나로는 어느 상태가 문제인지 알 수 없음

전체 평균 하나로는 그룹 사이의 차이가 묻힘

의미 있는 그룹으로 나눈 뒤 그룹마다 따로 집계

문제가 집중된 곳을 빠르게 찾아내는 도구

전체 평균도 유효한 요약이지만, 그룹별 수준과 분포 차이까지 보여 주지는 못함

유압 전체 평균 온도 45.34도 — 그런데 냉각기 정상은 35.89, 고장은 54.67

분할-적용-결합 구조

판다스의 그룹 집계는 항상 이 3단계로 작동

원본

전체 데이터

그룹으로 나누기 전 상태

01 · 분할

그룹별로 나눔

냉각기상태 기준이면 정상·저하·고장 세 덩어리, 아직 계산 없음

02 · 적용

각 그룹 계산

정상의 평균, 저하의 평균, 고장의 평균을 각각 계산

03 · 결합

결과 합침

각 그룹 결과를 하나의 표로 — 우리가 보는 최종 결과

적용 단계의 계산만 갈아 끼우면 평균·합계·최댓값 모두 구할 수 있음 — 분할은 그대로

groupby 기본 사용법

왼쪽에서 오른쪽으로 — 세 부분으로 끊어 읽기

01 · 그룹 기준 정하기

groupby 괄호 안에 — 줄을 나눌 열

02 · 집계할 열 고르기

[ ] 대괄호로 — 숫자로 답할 열

03 · 집계 함수 붙이기

.mean() 등 — 어떻게 계산할지

"df를 가지고, 냉각기상태로 그룹을 나눈 뒤, 온도 열을 골라서, 평균을 내라" — 문장처럼 끊어 읽기

posco

groupby 기본 코드

기준 → 열 → 집계 함수 순서로 읽기

CODE

```
means = df.groupby("냉각기상태")["온도"].mean()
print(means.round(2))
# 고장 54.67 · 저하 45.46 · 정상 35.89

print(df.groupby("냉각기상태")["온도"].max())
# 고장 57.8 · 저하 51.2 · 정상 36.4

print("평균 차이:", round(means.loc["고장"] - means.loc["정상"], 2))
# 18.78 — 표시용 반올림은 계산을 마친 다음에 적용
```

평균이 다르다는 관찰과 냉각기 상태가 원인이라는 주장은 구분해야 합니다.

실습 4. 그룹으로 나눠 재어 보기

기준을 정해 나눈 뒤 그룹마다 통계를 내 차이를 확인

목표

냉각기 상태별로 온도의 평균과 최댓값을 구해 세 상태가 얼마나 다른지 확인

단계

① 유압 사이클 파일을 읽어 냉각기 상태별 사이클 수를 세기

② 냉각기 상태로 그룹을 나눠 온도의 평균을 소수점 둘째 자리까지 구하기

③ 같은 기준으로 최댓값도 구해 평균과 나란히 비교하기

④ 가장 뜨거운 상태와 가장 시원한 상태의 평균 차이를 계산하기

예상 결과

세 상태 모두 40건씩 · 평균 54.67 · 45.46 · 35.89 · 차이 18.78도

여러 기준으로 그룹 묶기

고장이면서 고부하처럼 — 두 기준을 겹쳐 더 잘게 나눠 보기

01 · 여러 기준 묶기

그룹 기준 두 개 이상을 대괄호로 묶기

02 · 더 세밀한 그룹

기준들을 조합한 세밀한 그룹 생성

03 · 순서가 관점

기준 순서에 따라 보는 관점이 달라짐

냉각기 먼저면 상태별로 보이고, 부하 먼저면 부하별로 보임 — 목적에 맞게 순서 결정

여러 키 그룹 코드

냉각기 상태와 운전 부하를 동시에 고려

CODE

```
keys = ["냉각기상태", "운전부하"]
print(df.groupby(keys)["온도"].mean().round(2))
# 고장/고부하 55.51 · 고장/저부하 54.05
# 저하/고부하 44.07 · 저하/저부하 45.58
# 정상/고부하 35.89
print(df.groupby(keys).size())
# 17 · 23 · 3 · 37 · 40 (위 그룹 순서)
# 정상/저부하는 0건이라 이 문자열 열의 groupby 결과에 없음
```

정상 40건은 모두 고부하입니다. 전체 부하가 60:60이어도 각 상태의 부하 구성은 다릅니다.

두 기준 결과를 가로세로 표로 — crosstab

두 범주의 조합을 개수 표로 확인

비교	groupby 두 기준의 size	crosstab 기본 동작
결과 모양	관측된 조합이 세로로 나열	두 기준을 행과 열로 배치
이번 데이터	관측된 조합 5개	3행 × 2열
없는 조합	이 문자열 열에서는 결과 행 없음	정상 × 저부하 칸에 0
비율	그룹별 분모로 별도 계산	normalize="index"로 행별 비율

평균 표가 필요하면 groupby.mean().unstack() 또는 pivot_table을 사용할 수 있습니다.

crosstab · unstack 코드

건수의 0과 평균의 NaN은 의미가 다르다

CODE

```
print(pd.crosstab(df["냉각기상태"], df["운전부하"]))
#        고부하  저부하
# 고장       17    23
# 저하        3    37
# 정상       40     0

print(pd.crosstab(df["밸브상태"], df["result"],
                  normalize="index").round(3))
# 각 밸브 상태 안에서 result 라벨 비율을 계산 (각 행의 합 ≈ 1)

mean_table = df.groupby(["냉각기상태", "운전부하"])["온도"].mean()
print(mean_table.unstack().round(2))
# 정상/저부하는 NaN: 0℃가 아니라 측정 행이 없어 평균을 계산 못함
```

crosstab도 values·aggfunc를 지정하면 평균 등 다른 집계를 할 수 있습니다. 여기서는 빈도를 연습합니다.

size와 count 차이

그룹의 행 수와 값이 있는 칸 수를 구분

구분	size	count
세는 대상	그룹에 속한 행	각 열의 비결측 값
측정값 결측	행 수에 포함	해당 열에서는 제외
열 선택	선택 없이 그룹 행 수 계산	생략하면 각 열별로 계산
이 데이터의 결과	냉각기 상태별 40	온도도 상태별 40

그룹 기준 열의 결측은 기본적으로 제외됩니다. 필요하면 groupby(..., dropna=False)를 지정합니다.

03

종합 실습

빈도와 그룹 집계를 이어 추가 확인 대상 찾기

실습 5. 빈도와 그룹을 이어 보기

구성과 라벨 비율을 비교해, 추가로 확인할 상태를 제안하기

목표

밸브 상태별 전체 건수와 result 고장 건수를 구해 추가 확인 대상 고르기

단계

① 유압 사이클 파일을 읽어 밸브 상태별 건수를 세기

② 판정이 고장인 사이클만 걸러 새 변수에 담기

③ 걸러낸 결과를 밸브 상태별로 나눠 건수를 세기

④ 두 결과를 나눠 상태별 고장 라벨 비율을 구하고 가장 높은 상태를 확인

예상 결과

밸브 심각은 19건 중 14건이 고장 — 비율 0.737 로 가장 높음

실습 — 종합 산출물

숫자를 근거로 말하고, 해석 범위를 함께 적기

01

01 · 전체 구성

밸브 정상은 전체 120건 중 61건이다.
어떤 상태가 가장 많은지
건수와 비율로 설명한다.

02

02 · 그룹 비교

냉각기 고장 그룹 평균 온도는 54.67℃다.
정상 그룹보다 약 18.78℃ 높지만
일부 관측 범위는 겹친다.

03

03 · 추가 확인

밸브 심각의 고장 라벨 비율은 14/19다.
라벨 정의와 운전 조건을 먼저 확인한 뒤
추가 검토 대상을 제안한다.

관측된 사이클의 라벨 비율을 현장 고장 확률이나 설비 대수로 바꾸어 해석하지 않습니다.